Toolchain

• Системы компиляции



Как зовут преподавателя?

- Владимиров Константин Игоревич
- Телефон: +7-903-842-27-55
- Email: konstantin.vladimirov@gmail.com
- Где скачать слайды и конспект? sourceforge.net/projects/cpp-lects-rus
- Помощь в редактировании и исправлении ошибок приветствуется

Системы компиляции

- Более простое название toolchain (тулчейн)
- Набор средств для получения исполняемого файла из исходного кода





GNU Toolchain

LLVM Toolchain

Системы компиляции

\$ gcc -02 program.c -o program.x



Что при этом происходит?



Системы компиляции

\$ gcc -02 program.c -o program.x



Что при этом происходит?



- Вызов компилятора
- Вызов ассемблера
- Вызов линкера

GCC: как посмотреть что в действительности запустилось?

```
$ gcc -02 program.c --verbose -save-temps
```

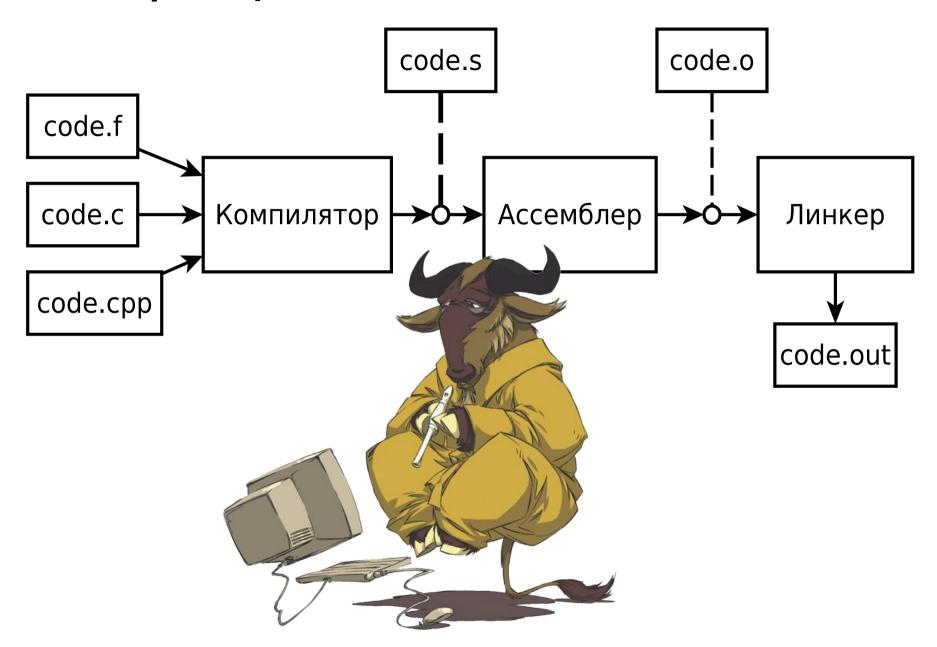
```
cc1 -E -quiet -v -imultiarch x86_64-linux-gnu program.c -mtune=generic -march=x86-64 -fpch-preprocess -o program.i
```

```
cc1 -fpreprocessed program.i -quiet -dumpbase program.c
-mtune=generic -march=x86-64 -auxbase program -version -o
program.s
```

```
as -v --64 -o program.o program.s
```

```
collect2 <....> program.o -lgcc --as-needed -lgcc_s --no-
as-needed -lc -lgcc --as-needed -lgcc_s --no-as-needed
crtn.o
```

Упрощённая схема toolchain



Toolchain

• Системы компиляции



Трансляция программы

- Вход: программа на одном из языков программирования
- Выход: ассемблер одной из архитектур
- Основная идея: отвязать компилятор от конкретного языка и ассемблера



Компилятор с птичьего полёта



Frontend

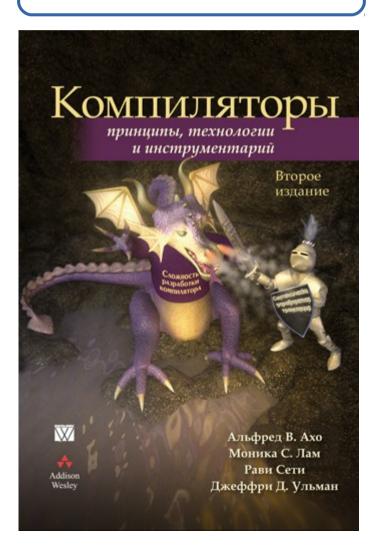
Препроцессинг
Лексический анализ
Синтаксический анализ
Семантический анализ
Построение HIR

Middleend + Backend

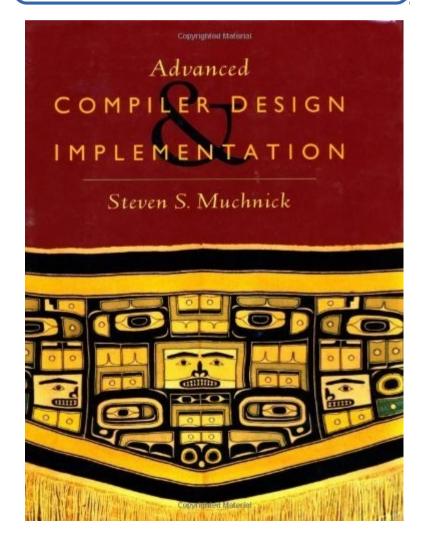
Оптимизации HIR Оптимизации MIR Оптимизации LIR Кодогенерация

Литература

Frontend



Middleend + Backend



Лексический анализ

- Ключевое понятие: лексема или токен
- Токен это пара тип/значение
- Исходный текст преобразуется в набор токенов

Препроцессинг

- Препроцессингом называется обработка исходного текста программы, до её синтаксического анализа
- Наивно думать, что препроцессинг происходит до лексического анализа. На самом деле препроцессинг это фаза лексера

С птичьего полёта это было не особо заметно....

Трансляция программы С++17

- Единица трансляции отображается в базовый набор символов, обрабатываются юникодные символы
- Конкатенируются строки, разбитые через \
- Комментарии заменяются на пробельные символы
- Файл разбивается на препроцессинговые токены
- Исполняются директивы препроцессора (include, define, прагмы)
- Заменяются еѕсаре-последовательности
- Соединяются строковые литералы
- Пробелы перестают иметь значение
- Препроцессинговые токены становятся токенами
- Проводится синтаксический анализ

Изучение работы препроцессора

```
int foo (int a) {
   // Will next line execute?\
   a += 1;
   return a;
}
```

• Произойдёт ли во время выполнения инкремент?

Изучение работы препроцессора

```
int foo (int a) {
   // Will next line execute?\
   a += 1;
  return a;
}
```



- Произойдёт ли во время выполнения инкремент?
- Нет, так как объединение строк предшествует удалению комментариев
- Но есть ли шансы узнать об этом заранее?

Трансляция программы С++17

- Единица трансляции отображается в базовый набор символов, обрабатываются юникодные символы
- Конкатенируются строки, разбитые через \
- Комментарии заменяются на пробельные символы
- Файл разбивается на препроцессинговые токены
- Исполняются директивы препроцессора (include, define, прагмы)
- Заменяются еѕсаре-последовательности
- Соединяются строковые литералы
- Пробелы перестают иметь значение
- Препроцессинговые токены становятся токенами
- Проводится синтаксический анализ



Изучение работы препроцессора

```
$ gcc --std=c11 -E foo.c -o foo.i
```

```
# 1 "<command-line>" 2
# 1 "prep-magic.c"
int foo (int a) {
  return a;
}
```

• Ещё больше проблем могут доставить директивы препроцессора и макросы

Изучение работы препроцессора

```
enum type t {
  OP IGNORED = 0x0, OP SRC = 0x1000,
  OP DST = 0x2000, OP DSTSRC = 0x3000
};
bool is_op_src (enum type t a) {
  return (a & OP SRC);
```

```
enum type_t x = OP_DSTSRC;
assert (is_op_src(x)); // FAILED!
```

После препроцессирования

```
enum type t {
  OP IGNORED = 0x0, OP SRC = 0x1000,
  OP DST = 0x2000, OP DSTSRC = 0x3000
};
char is op src (enum type t a) {
  return (a & OP SRC);
```

```
myheader.h:
#define bool char
// Happy debugging!
```

Применения препроцессора

• Использование по назначению

- Условное исключение кода из компиляции
- Модульная структура программы, включение заголовочных файлов
- Стражи включения
- Стрингификация и конкатенация

• Сомнительные применения

- Константы времени компиляции
- Синонимы типов
- Макросы (короткие обобщённые функции)

Обсуждение

```
#include <iostream>
int main () { cout << "Hello" << endl; }</pre>
```

- Как вы думаете сколько в ней окажется строк после препроцессирования?
- А сколько байт будет размер у препроцессированного файла?

Обсуждение

```
#include <iostream>
int main () { cout << "Hello" << endl; }</pre>
```

- Как вы думаете сколько в ней окажется строк после препроцессирования?
- А сколько байт будет размер у препроцессированного файла?

В моей реализации:

g++ 24706 loc, 704835 bytes

clang++ 37838 loc, 1004278 bytes

Вдумайтесь в эти результаты: мегабайт текста из одной строчки.

Предварительно собранные заголовочные файлы

• Традиционное расширение большинства компиляторов

```
$ g++ -c stdafx.h -o stdafx.h.gch
```

stdafx.h

```
#include <cassert>
#include <iostream>
#include <string>
#include <vector>
```



stdafx.h.gch

• Использует gch там где есть обычный include

Проблема зависимостей

• Представьте, что вам надо решить что писать в Makefile как правило сборки

```
x.o: x.c inc.h
$(CC) x.c -o $@
```

• Но что, если inc.h сам по себе включает некий другой хедер?

```
// inc.h
#include "inc2.h"
```

```
x.o : x.c inc.h inc2.h $(CC) x.c -o $@
```

Проблема зависимостей

• Разумеется, сбор зависимостей следует автоматизировать (тоже в препроцессоре)

```
// x.c
#include "inc.h"

#include "inc.h"

#include "inc2.h"
```

```
$ gcc -M user.c
user.o: user.cc /usr/include/stdc-predef.h inc.h inc2.h
$ gcc -MM user.c
user.o: user.cc inc.h inc2.h
$ gcc -MMD user.c
```

Фронтенд

- Лексический анализ
- → Синтаксический анализ
- Раскрытие шаблонов
- Вывод типов
- Построение AST



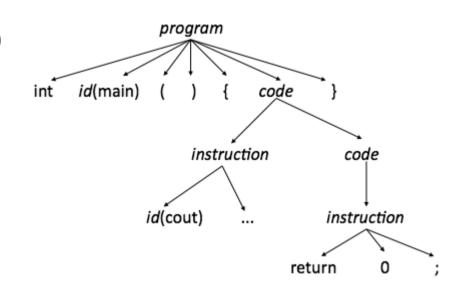
```
C / C++ / Fortran / ...
```



Syntax tree (HIR)

Синтаксический анализ

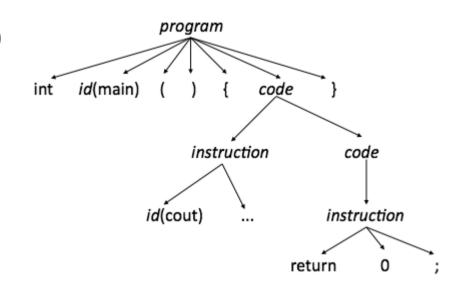
- Синтаксический разбор
- Построение AST
- Разбор может быть нетривиальным (особенно в С++)



Пример. Что здесь написано?

Синтаксический анализ

- Синтаксический разбор
- Построение AST
- Разбор может быть нетривиальным (особенно в С++)

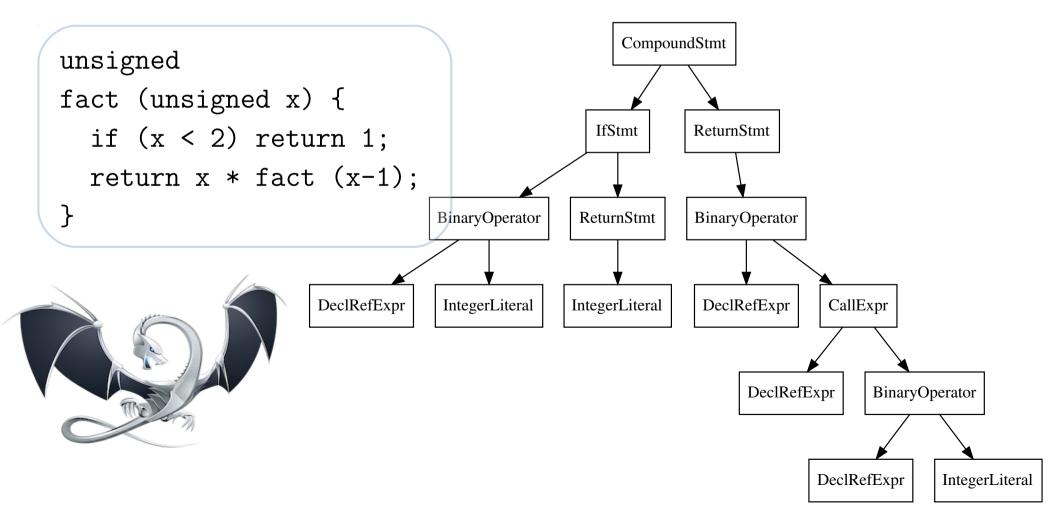


Пример 2. Что здесь написано?

```
template <class T> foo (T x) {
   T::iterator *y;
   /* .... */
}
```

Исследование AST

\$ clang -cc1 -ast-view fact.c

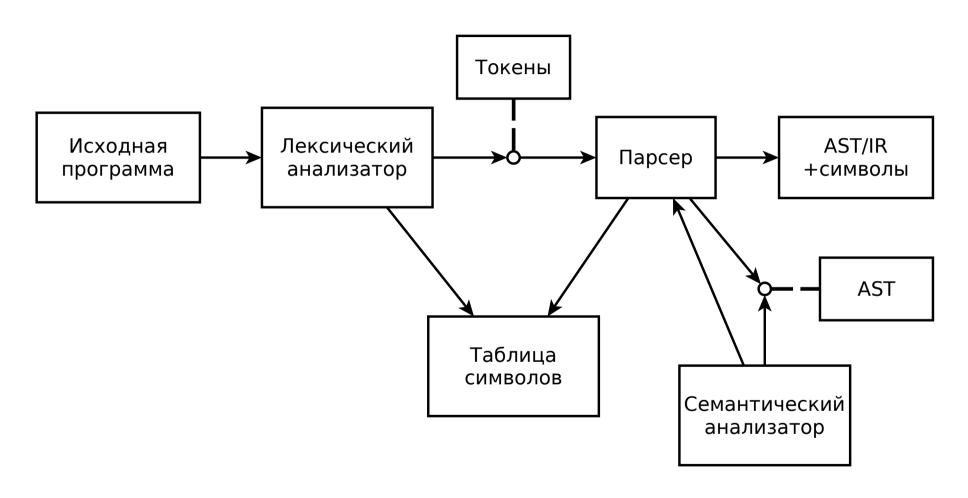


Синтаксические макросы?

- В некоторых языках обработка до синтаксического анализа (препроцессор) заменена на возможность модифицировать сам синтаксический анализ
- Пример: синтаксические макросы в LISP
- Как по вашему, сделает ли это вещи существенно проще?
- Хотели бы вы сделать язык, где есть и то и другое?
- А сами писать на таком языке?
- А чтобы на нём писал ваш заклятый враг?
- Предположим, что вы ненавидите всё человечество. В этом случае как бы вы отнеслись к идее добавить синтаксические макросы в C++?



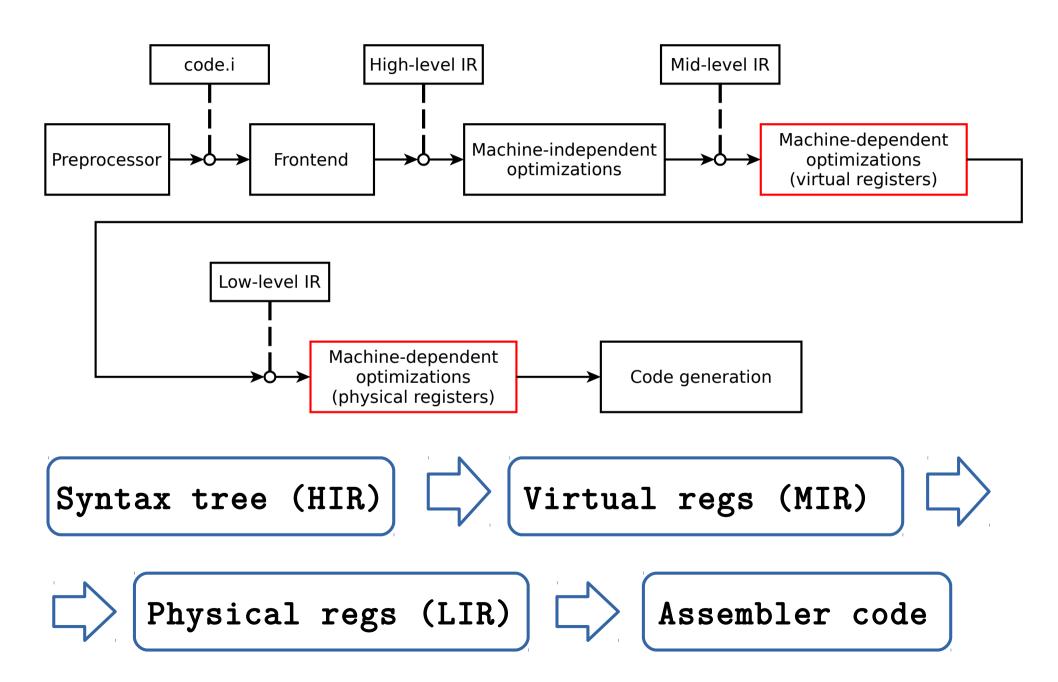
Фронтенд (упрощённая схема)



Фронтенд (упрощённая схема)



Что после фронтенда?



IR B GCC

GENERIC

RTL (virtual regs)

Gimple

RTL (physical regs)

Gimple SSA

Зачем их так много?



SSA: static single assignment

```
y1 = x1 + 1;
x2 = 2;
  z = x2 + 1;
```

SSA: static single assignment

```
x1 = 1;
                 y1 = x1 + 1;

x2 = 2;
                   z = x2 + 1;
z = x + 1;
```

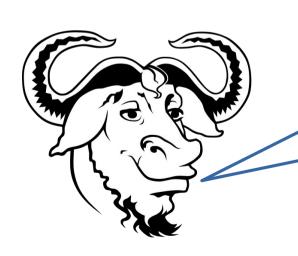
Проблема: как быть с ветвлениями и циклами?

SSA: static single assignment

```
x = input ()
x = input ();
if (x > 42)
                                        yes
                                               x > 42?
   y = 1;
else
                                    y1 = 1
                                                         y2 = x + 2
   y = x + 2;
                                             y = phi (y1, y2)
use (y);
                                                use (y)
```

GCC: как получить дампы IR?

- -fdump-tree-all-<options>
- -fdump-rtl-all-<options>
- Можно получать графические дампы, если передать <options> == graph



За полезными опциями всегда можно заглянуть сюда:

https://gcc.gnu.org/onlinedocs/gcc/

GCC: как читать gimple дампы

```
if (x < 2)
  return 1;

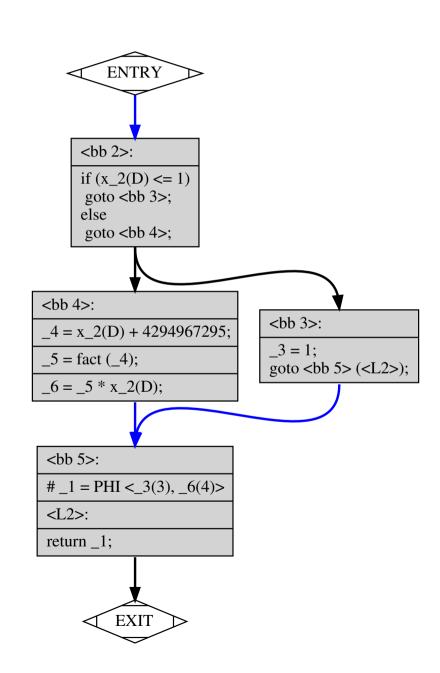
return
  x * fact (x-1);</pre>
```



```
<bb 3>:
  3 = 1;
  goto <bb 5> (<L2>);
  <bb 4>:
  4 = x 2(D) + 4294967295;
  _{5} = fact (_{4});
  _{6} = _{5} * x_{2}(D);
<bb 5>:
  # 1 = PHI <_3(3), _6(4)>
<L2>:
  return 1;
```

Перевод в SSA форму

```
unsigned
fact (unsigned x)
  if (x < 2)
    return 1;
  return
    x * fact (x-1);
```



Машинно-независимые преобразования

```
ENTRY
unsigned
                                             <bb >>:
fact (unsigned x)
                                             \# x \ 3 = PHI < x \ 4(D)(0), \ 6(3) >
                                             # mult acc 10 = PHI < 1(0), mult acc 9(3) >
                                             if (x \ 3 \le 1)
                                             goto <bb 4>;
   if (x < 2)
                                             else
                                             goto <bb 3>;
       return 1;
                                                                             <bb 4>:
                                             <bb >>:
                                                                             \#_1 = PHI < 1(2) >
   return
                                             _6 = x_3 + 4294967295;
                                                                             mul_tmp_8 = mult_acc_10 * _1;
                                             mult acc 9 = \text{mult} acc 10 * x 3;
       x * fact (x-1);
                                             goto <bb 2>;
                                                                             return mul tmp 8;
                                                                                        EXIT
```

GCC: как читать RTL дампы

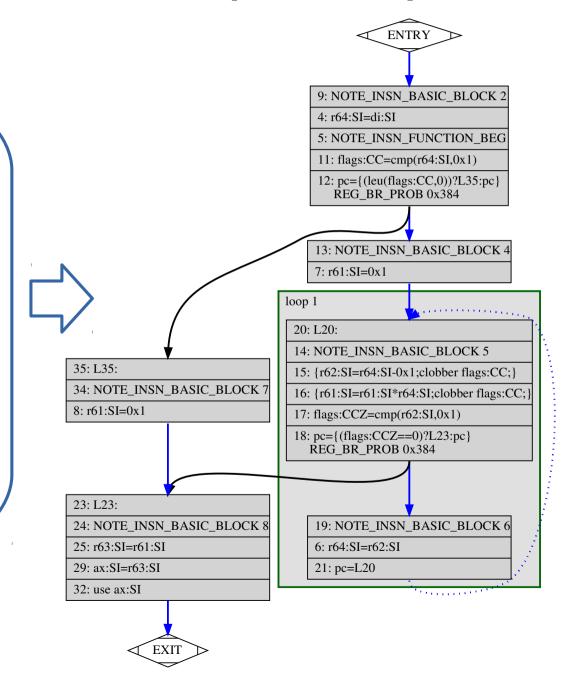
```
_{6} = x_{7} + 4294967295
```





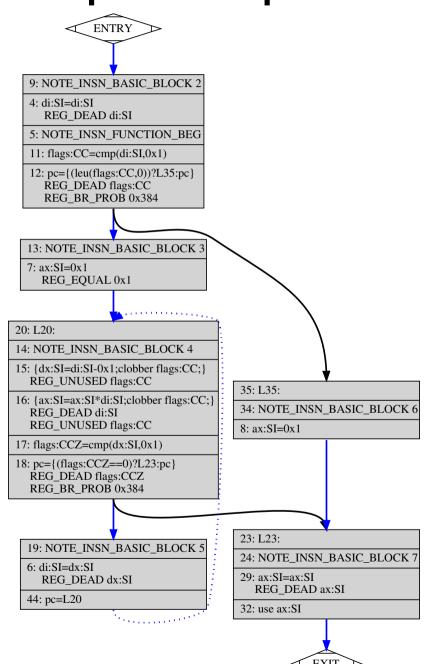
RTL с виртуальными регистрами

```
unsigned
fact (unsigned x)
  if (x < 2)
    return 1;
  return
    x * fact (x-1);
```



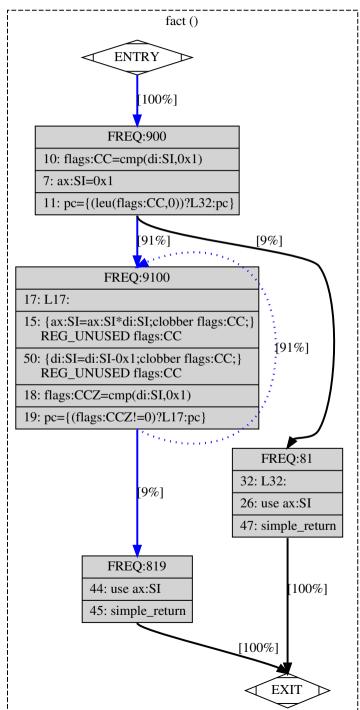
RTL с физическими регистрами

```
unsigned
fact (unsigned x)
  if (x < 2)
    return 1;
  return
    x * fact (x-1);
```



Машинно-зависимые преобразования

```
unsigned
fact (unsigned x)
  if (x < 2)
    return 1;
  return
    x * fact (x-1);
```



Итоговый ассемблер

```
unsigned
fact (unsigned x)
  if (x < 2)
    return 1;
  return
    x * fact (x-1);
```



```
.p2align 4,,15
  .globl fact
  .type fact, @function
fact:
.LFBO:
  .cfi startproc
  cmpl $1, %edi
 movl $1, %eax
  jbe .L4
  .p2align 4,,10
  .p2align 3
.L3:
  imull %edi, %eax
  subl $1, %edi
  cmpl $1, %edi
  jne .L3
 rep; ret
.L4:
  rep; ret
  .cfi_endproc
```

Итоговый ассемблер: аннотация RTL

```
$ gcc -02 -S fact.c -dP
```

```
#(insn 8 11 12 2 (set (reg:SI 0 ax [orig:61 D.1741 ] [61])
        (const_int 1 [0x1])) fact.c:4 89 {*movsi_internal}
     (nil))
        movl $1, %eax #8 *movsi internal/1 [length = 5]
#(jump_insn:TI 12 8 56 2 (set (pc)
#
        (if_then_else (gtu (reg:CC 17 flags)
                (const int 0 [0]))
            (label ref:DI 20)
            (pc))) fact.c:4 612 {*jcc_1}
     (expr list:REG DEAD (reg:CC 17 flags)
        (expr list:REG BR PROB (const int 9100 [0x238c])
            (nil)))
# -> 20)
               .L3 # 12 *jcc_1 [length = 2]
        ja
```

Toolchain

• Системы компиляции



Ассемблер

- Язык ассемблера (например X86 ассемблер)
- Ассемблер как программа (например GAS)
- Ассемблирование как процесс

.text .p2align 4,,15 .globl fact Инструкции .type fact, @function fact: .LFB0: .cfi startproc cmpl \$1, %edi movl \$1, %eax jbe .L4 .p2align 4,,10 .p2align 3 .L3: imull %edi, %eax subl \$1, %edi cmpl \$1, %edi jne .L3 rep; ret

.L4:

rep; ret

.cfi_endproc

Инструкции

Директивы

```
.text
  .p2align 4,,15
  .globl fact
  .type fact, @function
fact:
.LFBO:
  .cfi startproc
  cmpl $1, %edi
 movl $1, %eax
  jbe .L4
  .p2align 4,,10
  .p2align 3
.L3:
  imull %edi, %eax
  subl $1, %edi
  cmpl $1, %edi
  jne .L3
 rep; ret
.L4:
  rep; ret
  .cfi endproc
```

.text .p2align 4,,15 Инструкции .globl fact .type fact, @function fact: .LFBO: .cfi startproc Директивы cmpl \$1, %edi movl \$1, %eax jbe .L4 .p2align 4,,10 Метки .p2align 3 .L3: imull %edi, %eax subl \$1, %edi cmpl \$1, %edi jne .L3 rep; ret .L4: rep; ret .cfi endproc

Инструкции

Директивы

Метки

Секции

```
.text
  .p2align 4,,15
  .globl fact
  .type fact, @function
fact:
.LFBO:
  .cfi startproc
  cmpl $1, %edi
  movl $1, %eax
  jbe .L4
  .p2align 4,,10
  .p2align 3
.I.3:
  imull %edi, %eax
  subl $1, %edi
  cmpl $1, %edi
  jne .L3
  rep; ret
.L4:
  rep; ret
  .cfi endproc
```

Инструкции

Директивы

Метки

Секции

DWARF

```
.text
  .p2align 4,,15
  .globl fact
  .type fact, @function
fact:
.LFBO:
   cfi startproc
  cmpl $1, %edi
  movl $1, %eax
  jbe .L4
  .p2align 4,,10
  .p2align 3
.I.3:
  imull %edi, %eax
  subl $1, %edi
  cmpl $1, %edi
  jne .L3
  rep; ret
.L4:
  rep; ret
  .cfi endproc
```

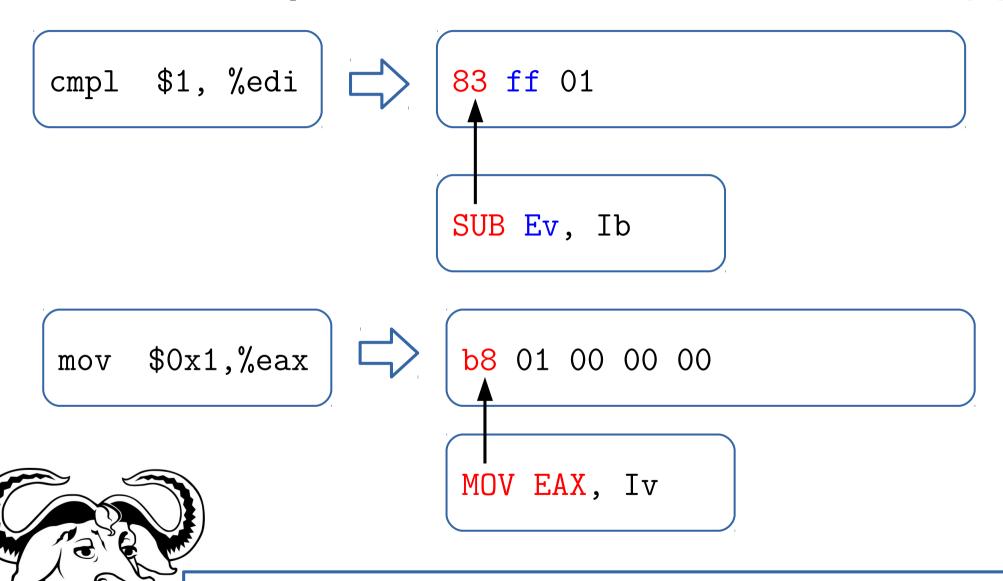
Ассемблер Х86: разный синтаксис

\$ gcc -02 -S -masm=[intel|att] program.c

```
.globl fact
  .type fact, @function
fact:
  cmp edi, 1
 mov eax, 1
 jbe .L4
  .p2align 4,,10
  .p2align 3
.L3:
  imul eax, edi
  sub edi, 1
  cmp edi, 1
  jne .L3
 rep ret
.L4:
 rep ret
```

```
.globl fact
  .type fact, @function
fact:
  cmpl $1, %edi
 movl $1, %eax
 jbe .L4
  .p2align 4,,10
  .p2align 3
.L3:
  imull %edi, %eax
  subl $1, %edi
 cmpl $1, %edi
 jne .L3
 rep; ret
.L4:
 rep; ret
```

Ассемблирование: машинный код



http://sparksandflames.com/files/x86InstructionChart.html

Ассемблирование: сборка секций

```
.text
..... some code ......
                                     ELF object file header
.data
..... some data ......
                                     Program header table
.text
..... more code ......
                                     .text
                                     .... encoded instructions ...
.data
..... more data ......
                                     .data
.text
                                     Section header table
..... more code ......
.text
..... more code ......
```



• Макросы

```
.macro sum from=0, to=5
  .long \from
  .if \to-\from
  sum "(\from+1)",\to
  .endif
.endm
```

Как использовать этот макрос?

• Макросы

```
.macro sum from=0, to=5
  .long \from
  .if \to-\from
  sum "(\from+1)",\to
  .endif
```

sum 0, 5



- .long 0
- .long 1
- • •
- .long 5



• Макросы



• Включение файлов

```
.macro sum from=0, to=5
  .long \from
  .if \to-\from
  sum "(\from+1)",\to
  .endif
.endm
```

.include "other.s"

• Макросы



- Включение файлов
- Комментарии

```
.macro sum from=0, to=5
  .long \from
  .if \to-\from
  sum "(\from+1)",\to
  .endif
.endm
```

```
.include "other.s"
```

```
ja .L3 # 12 *jcc_1
```

• Макросы



- Включение файлов
- Комментарии
- Дополнительные возможности

```
.macro sum from=0, to=5
  .long \from
  .if \to-\from
  sum "(\from+1)",\to
  .endif
.endm
```

```
.include "other.s"
```

```
ja .L3 # 12 *jcc_1
```

```
melvin: .long .
```

Что содержит melvin?

• Макросы



- Включение файлов
- Комментарии
- Дополнительные возможности

```
.macro sum from=0, to=5
  .long \from
  .if \to-\from
  sum "(\from+1)",\to
  .endif
.endm
```

```
.include other.s
```

```
ja .L3 # 12 *jcc_1
```

```
// melvin = &melvin
melvin: .long .
```

Локальные метки

```
.L1:
   cmpl $2, %edi
        .L2
   jg
   cmpl $-9, %edi
          .L1
   jge
.L2:
   cmpl $-9, %edi
       .L3
   jge
   cmpl $2, %edi
   jle
       .L3
   cmpl $0, %edi
          .L2
   jg
.L3:
```



```
cmpl $2, %edi
         1f
   jg
   cmpl $-9, %edi
   jge
         1b
1:
         $-9, %edi
   cmpl
   jge
          1f
   cmpl $2, %edi
   jle
         1f
         $0, %edi
   cmpl
          1b
   jg
```

objdump: дизассемблирование

```
$ as fact.s --64 -o fact.o
$ objdump -d fact.o > fact.d
 fact:
  cmpl $1, %edi
  movl $1, %eax
                         0000000000000000 <fact>:
  jbe .L4
                               83 ff 01
  .p2align 4,,10
  .p2align 3
                           8: 76 13
 .1.3:
  imull %edi, %eax
                          10: Of af c7
  subl $1, %edi
                          13: 83 ef 01
  cmpl $1, %edi
                          16: 83 ff 01
  jne .L3
```

rep; ret

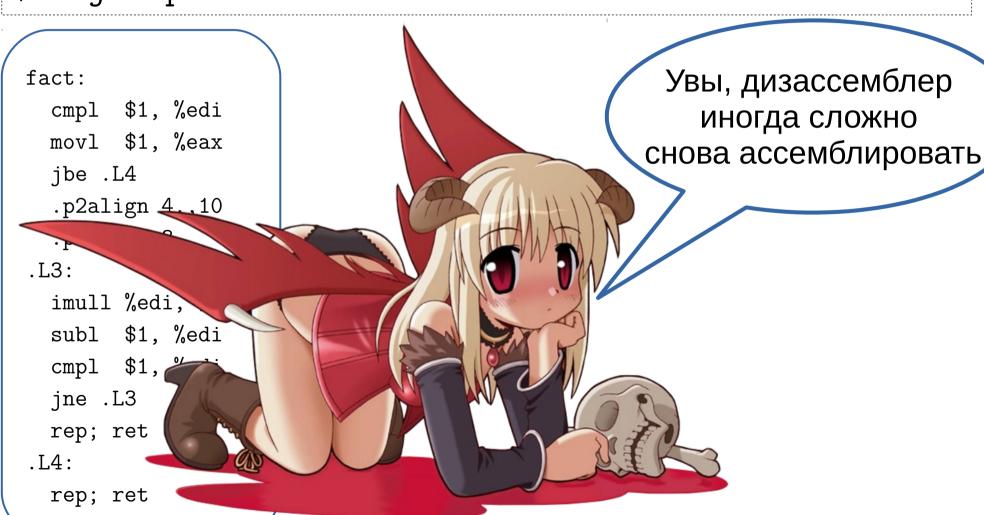
rep; ret

.T.4:

```
file format elf64-x86-64
Disassembly of section .text:
                               $0x1, %edi
                        cmp
  3: b8 01 00 00 00
                               $0x1, %eax
                        mov
                              1d <fact+0x1d>
                        jbe
  a: 66 Of 1f 44 00 00
                              0x0(\%rax,\%rax,1)
                        nopw
                        imul
                              %edi,%eax
                        sub
                              $0x1,%edi
                               $0x1,%edi
                        cmp
 19: 75 f5
                        jne 10 < fact + 0x10 >
  1b: f3 c3
                        repz retq
  1d:
       f3 c3
                        repz retq
```

objdump: дизассемблирование

```
$ as fact.s --64 -o fact.o
$ objdump -d fact.o > fact.d
```



Усложненный пример факториала

```
fact.c
unsigned
fact (unsigned x)
  if (x < 2)
    return 1;
  return
    x * fact (x-1);
```

```
main.c
int
main (void)
  unsigned f = fact(5);
  printf ("u\n", f);
  return 0;
```

Как будут скомпилированы вызовы fact и printf в main.o?

С: объявления и определения

- Объявление (declaration) вводит имя и сигнатуру для компилятора
- Определение (definition) содержит реализацию (тело функции, etc)

```
int printf (const char *fmt, ...)
unsigned fact (unsigned);
int
main (void) {
    ..... call printf and fact .....
}
```

libc.a

fact.o

С: объявления и определения

- Объявление (declaration) вводит имя и сигнатуру для компилятора
- Определение (definition) содержит реализацию (тело функции, etc)

```
#include <stdio.h>
#include "fact.h"

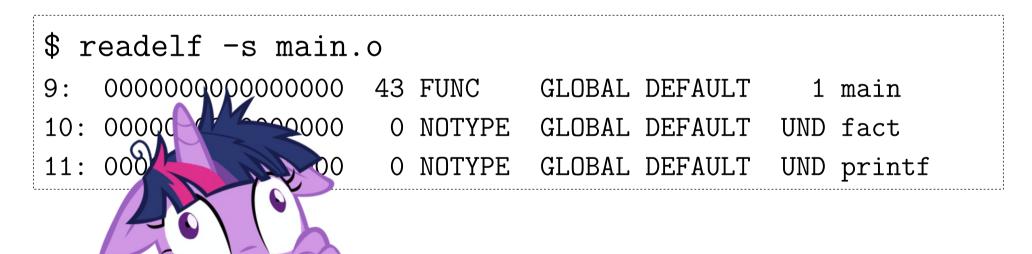
int
main (void) {
   ..... call printf and fact .....
}
```

libc.a

fact.o

Попытка собрать main.c

```
$ gcc -02 main.c -save-temps
main.o: In function `main':
main.c:(.text+0xa): undefined reference to `fact'
collect2: ld returned 1 exit status
```



Попытка собрать main.c

```
$ gcc -02 main.c -save-temps
main.o: In function `main':
main.c:(.text+0xa): undefined reference to `fact'
collect2: ld returned 1 exit status
```

```
$ readelf -s main.o
9: 000000000000000 43 FUNC GLOBAL DEFAULT 1 main
10: 0000000000000 0 NOTYPE GLOBAL DEFAULT UND fact
11: 00000000000000 0 NOTYPE GLOBAL DEFAULT UND printf
```

Пора задействовать линкер!

Toolchain

• Системы компиляции



Линковка (Linking)

- Сборка объектных модулей в исполняемый файл или динамическую библиотеку
- Разрешение межмодульных зависимостей
- Проверка ошибок неопределенных или многократно определенных символов



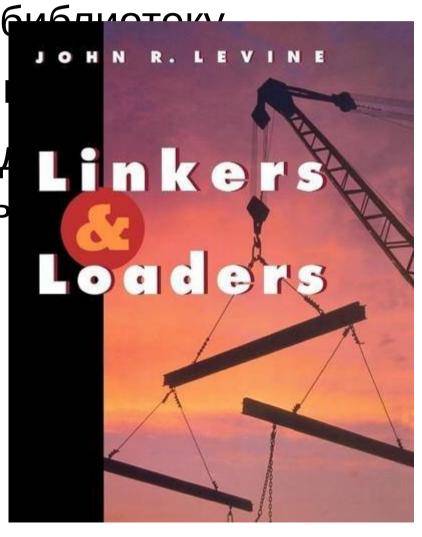
Линковка (Linking)

• Сборка объектных модулей в исполняемый файл или динамическую библистом.

• Разрешение межмодульн

• Проверка ошибок неопред при многократно определенны





Статическая линковка

```
$ gcc fact.c main.c -static -save-temps
```

fact.c

```
unsigned
fact (unsigned x)
  if (x < 2)
    return 1;
  return
    x * fact (x-1);
```

main.c

```
int
main (void)
{
  unsigned f = fact(5);
  printf ("%u\n", f);
  return 0;
}
```

Релокации

```
$ gcc fact.c main.c -static -save-temps
$ objdump -d main.o > main.dis
```

000000000000000 <main>:

0: 55 push %rbp

1: 48 89 e5 mov %rsp,%rbp

4: bf 05 00 00 00 mov \$0x5, %edi

9: **e8 00 00 00 00** callq e <main+0xe>

e: 89 c2 mov %eax, %edx

• • • •

Релокации

```
$ gcc fact.c main.c -static -save-temps
$ objdump -d a.out > result.dis
```

```
0000000000400434 <main>:
```

400434: 55 push %rbp

400435: 48 89 e5 mov %rsp,%rbp

400438: bf 05 00 00 00 mov \$0x5, %edi

40043d: **e8 1e 00 00 00** callq 400460 <fact>

400442: 89 c2 mov %eax, %edx

• • • •

0000000000400460 <fact>:

400460: 55 push %rbp

400461: 48 89 e5 mov %rsp,%rbp

Статическая линковка факториала: разбивка по шагам

\$ gcc -02 fact.c main.c -static -save-temps



```
$ gcc -02 fact.c -c -o fact.o
$ gcc -02 main.c -c -o main.o
$ gcc fact.o main.o -static -o fact.x
```

Статическая линковка факториала: разбивка по шагам

\$ gcc -02 fact.c main.c -static -save-temps



```
$ gcc -02 fact.c -c -o fact.o
$ gcc -02 main.c -c -o main.o
$ ld fact.o main.o -static -o fact.x
```

Статическая линковка факториала: разбивка по шагам

\$ gcc -02 fact.c main.c -static -save-temps



```
$ gcc -02 fact.c -c -o fact.o
$ gcc -02 main.c -c -o main.o
$ ld fact.o main.o -static -o fact.x
```

```
ld: warning: cannot find entry symbol _start;
defaulting to 00000000004000b0
main.o: In function `main':
main.c:(.text.startup+0x1d): undefined reference to
`__printf_chk'
```

Статические библиотеки

\$ gcc fact.o main.o -static --verbose



collect2 -m elf_x86_64 -static crtbeginT.o -L.
-L<other paths here> main.o fact.o --start-group
-lgcc -lgcc eh -lc --end-group crtend.o crtn.o

Где-то здесь прячется printf...



Статические библиотеки своими руками

```
$ gcc -02 fact.c -c -o fact.o
$ ar -cr libfact.a fact.o
$ gcc -static main.c -L. -lfact
```

- определение функции fact внутри libfact.a
- определение функции printf внутри libc.a
- общепринятое сокращение:
 - -Ismth == libsmth.a
- упаковщик **ar** пакует объектные файлы в статические библиотеки

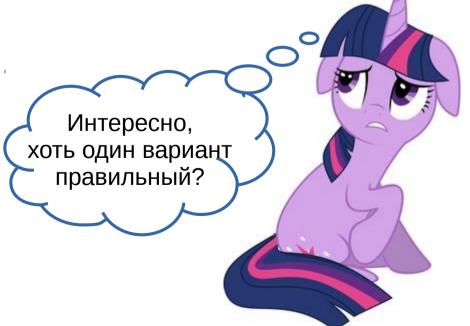
Порядок линковки имеет значение

```
extern int a;
int main() {
  return a;
}

b.c libb.a d.c libd.a

extern int b;
int a;
// ....
a = b;
```

```
$ gcc -L. -lb -ld a.c
$ gcc -L. -ld -lb a.c
$ gcc a.c -L. -ld -lb
$ gcc a.c -L. -lb -ld
```



Порядок линковки имеет значение

```
libb.a
                                         d.c
                                                  libd.a
       a.c
                     extern int b;
  extern int a;
  int main() {
                     int a;
                                         int b;
    return a;
                     a = b;
$ gcc -L. -lb -ld a.c
$ gcc -L. -ld -lb a.c
$ gcc a.c -L. -ld -lb
$ gcc a.c -L. -lb -ld
```

Порядок линковки имеет значение

```
extern int a; int main() {
 return a; }
}

b.c libb.a d.c libd.a

extern int b; int a; int b;

// ....

a = b;
```

```
$ gcc -L. -Wl,-\( -lb -ld -Wl,-\) a.c

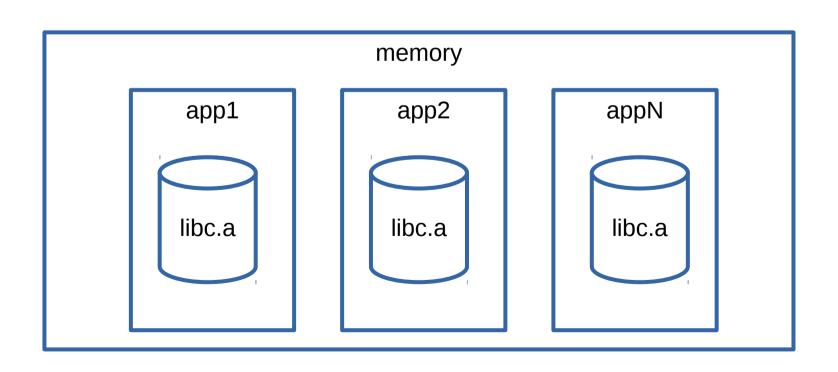
$ gcc -L. -Wl,-\( -ld -lb -Wl,-\) a.c

$ gcc a.c -L. -Wl,-\( -ld -lb -Wl,-\)

$ gcc a.c -L. -Wl,-\( -ld -lb -Wl,-\)
```

Проблемы статических библиотек

- Большой размер исполняемых файлов
- При исполнении нескольких файлов, библиотека оказывается загружена несколько раз

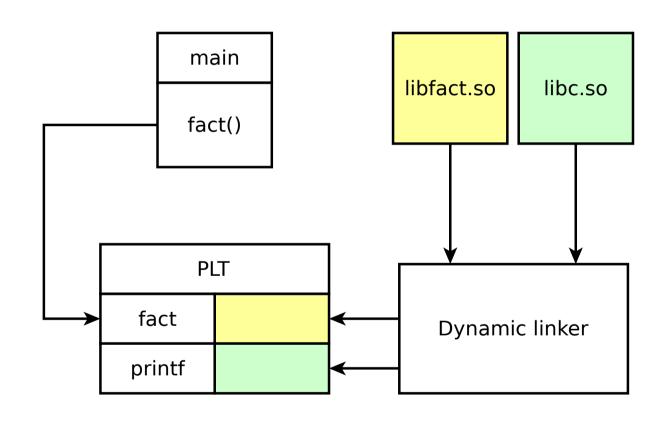


Проблемы статических библиотек

- Большой размер исполняемых файлов
- При исполнении нескольких файлов, библиотека оказывается загружена несколько раз
- Решение: динамические библиотеки

```
$ gcc -02 -fPIC fact.c -c -o fact.o
$ gcc -shared fact.o -o libfact.so
$ gcc main.c -L. -lfact -Wl,-rpath,.
```

```
main:
.LFBO:
  .cfi startproc
 pushq %rbp
  .cfi_def_cfa_offset 16
  .cfi_offset 6, -16
 movq %rsp, %rbp
  .cfi def cfa register 6
 movl $5, %edi
  call fact@PLT
 movl %eax, %esi
  leaq .LCO(%rip), %rdi
 movl $0, %eax
  call printf@PLT
```



```
unsigned lookup[] =
{1, 1, 2, 6, 24, 120, 720,
5040, 40320, 362880,
3628800, 39916800,
479001600};
unsigned fact (unsigned x)
  assert (x < 13);
  return lookup[x];
```

```
fact:
.LFB0:
.cfi_startproc
cmpl $12, %edi
ja .L5
movl %edi, %edi
movl lookup(,%rdi,4), %eax
ret
```

```
$ gcc fact-lookup.c -S -02
```

```
unsigned lookup[] =
{1, 1, 2, 6, 24, 120, 720,
5040, 40320, 362880,
3628800, 39916800,
479001600};
unsigned fact (unsigned x)
  assert (x < 13);
  return lookup[x];
```

```
fact:
.LFBO:
.cfi startproc
cmpl $12, %edi
    .L5
ja
movq
 lookup@GOTPCREL(%rip), %rax
movl %edi, %edi
movl (%rax, %rdi, 4), %eax
ret
```

\$ gcc fact-lookup.c -S -02 -fPIC

```
extern
unsigned lookup[];
unsigned
fact (unsigned x)
  assert (x < 13);
  return lookup[x];
```



```
00000000004006dd <fact>:
                 %rbp
4006dd:
          push
                 %rsp,%rbp
4006de:
          mov
                 $0x10,%rsp
4006e1: sub
                 %edi,-0x4(%rbp)
4006e5:
          mov
4006e8: cmpl
                 \$0xc,-0x4(\%rbp)
4006ec:
          jbe
                 40070d <fact+0x30>
// some assert-related stuff
                 0x2008e4(%rip),%rax
40070d:
          mov
                 -0x4(\%rbp),%edx
400714:
          mov
400717:
                 (\%rax,\%rdx,4),\%eax
          mov
40071a:
          leaveg
40071b:
          reta
```

\$ gcc fact-lookup.c -L. -lfact-lookup-table



```
00000000004006dd <fact>:
           push
4006dd:
                   %rbp
                   %rsp,%rbp
4006de:
           mov
                   $0x10,%rsp
4006e1:
           sub
                   %edi,-0x4(%rbp)
4006e5:
           mov
                   $0xc,-0x4(\%rbp)
4006e8:
           cmpl
4006ec:
                   40070d <fact+0x30>
           jbe
// some assert-related stuff
                   0x2008e4(%rip),%rax
40070d:
           mov
                   -0x4(\%rbp),%edx
400714:
           mov
                   (%rax, %rdx, 4), %eax
400717:
           mov
40071a:
           leaveg
40071b:
           reta
```

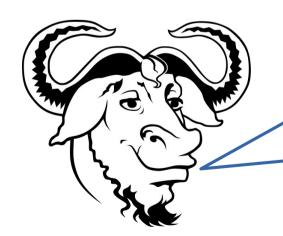
адрес 0х2008е4 похож на глобальные данные



```
00000000004006dd <fact>:
           push
4006dd:
                  %rbp
                  %rsp,%rbp
4006de:
           mov
                  $0x10,%rsp
4006e1:
           sub
                  %edi,-0x4(%rbp)
4006e5:
           mov
                  $0xc,-0x4(\%rbp)
4006e8:
           cmpl
4006ec:
                  40070d <fact+0x30>
           jbe
// some assert-related stuff
                  0x2008e4(%rip) %rax
40070d:
           mov
                   -0x4(\%rbp), %edx
400714:
           mov
                   (%rax, %rdx, 4), %eax
400717:
           mov
40071a:
           leaveg
40071b:
           reta
```

LDD: анализ динамических зависимостей и библиотек

```
$ ldd a.out
linux-vdso.so.1 => (0x00007fff6956b000)
libfact.so => ./libfact.so (0x00007f86adf83000)
libc.so.6 => /lib/libc.so.6 (0x00007f86adbd2000)
/lib64/ld-linux-x86-64.so.2 (0x00007f86ae186000)
```



Пути здесь зависят от опции rpath, поданной на линковке

```
$ gcc -02 main.c -L. -lfact -Wl,-rpath,.
```

Реально подключенные библиотеки

```
$ gcc test.c -lfact -L. --verbose
collect2 --eh-frame-hdr -m elf_x86_64
-dynamic-linker ld-linux-x86-64.so.2 crt1.o crti.o
crtbegin.o -L. -L/lib/../lib64 -L/usr/lib/../lib64
test.o -lfact -lgcc -lc -lgcc --as-needed -lgcc_s
--no-as-needed crtend.o crtn.o
```

- crtbegin, crtend, crt1, crti, crtn называются стартовыми файлами
- Именно там находятся настоящее начало и конец программы

Проблемы динамических библиотек

- Большие накладные расходы на вызов функции (обращении к глобальным данным)
- Иногда хочется критичные библиотеки (lfact) линковать статически, а некритичные, но большие (lc) динамически
- Решение: смешанная линковка

```
$ gcc test.c -W1,-Bstatic -lfact -W1,-Bdynamic -L.
```

• Опция -WI транслирует опцию линкеру

Проблемы динамических библиотек

• Слишком большое число экспортируемых функций увеличивает время загрузки

```
// user needs this
unsigned myfunc (unsigned);

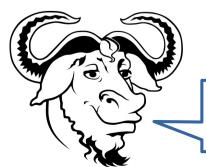
// these ones can not be static, because library
// is multi-file, but they vaste export table space
unsigned helper1 (unsigned);
unsigned helper2 (unsigned);
// ... here goes 40 more helpers
```

Проблемы динамических библиотек

• Решение: управление видимостью

```
__attribute__ ((visibility(default)))
unsigned myfunc (unsigned);
unsigned helper1 (unsigned);
unsigned helper2 (unsigned);
// .... here goes 40 more helpers
```

```
$ gcc dl1.c dl2.c -fvisibility=hidden
```

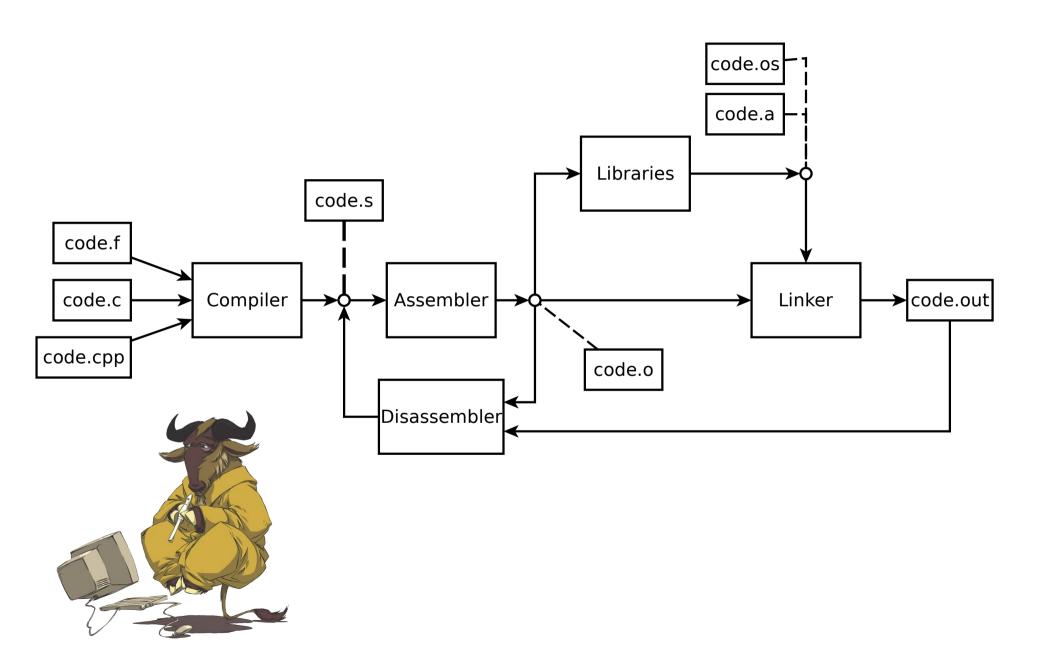


Больше информации здесь: https://gcc.gnu.org/wiki/Visibility

Подмена динамических библиотек

- Динамический линкер заполняет PLT/GOT на каждом запуске программы
- Что если те же таблицы заполнить до него чем-то другим?
- Для подмены используется LD_PRELOAD
- \$ gcc -dynamic -02 myprog.c -o a.out
- \$ LD_PRELOAD=/path/to/some.so a.out
- Эта немного хакерская техника очень полезна (пример: failmalloc)

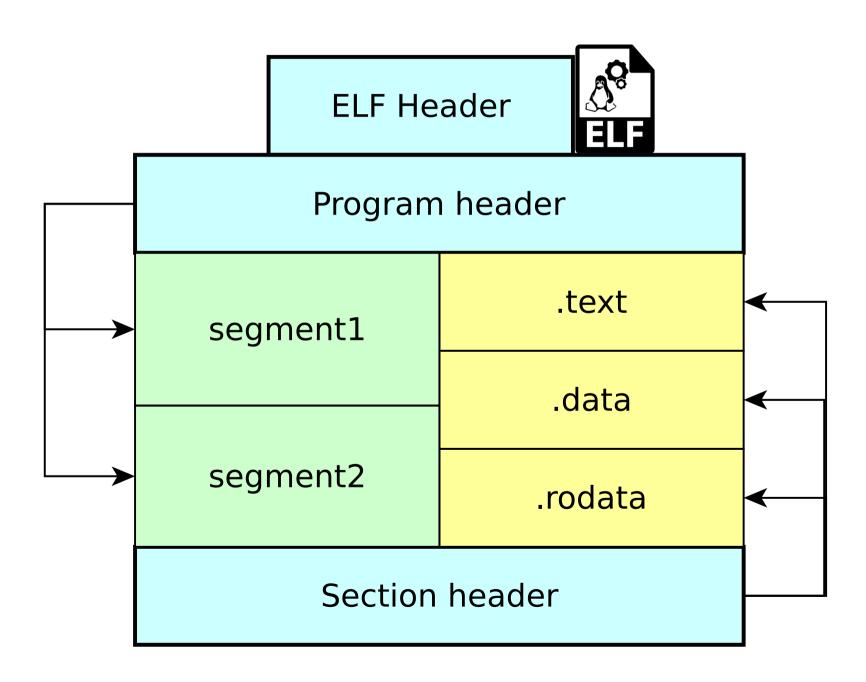
Уточнённая схема toolchain



Форматы выходных файлов

- ELF де-факто стандарт для исполняемого и объектного кода в Unix-подобных системах
- PE де-факто стандарт (включая свою доработку PE32+) для исполняемого кода в Windows-подобных системах
- COFF популярен (как и его доработка ECOFF) для объектных файлов
- a.out древний, но всё ещё популярный за свою минималистичность формат

ELF – executable and linkable format



Исследование section header

\$ readelf -S a.out --wide

[Nr]	Name	Туре	Address	Off	Size	ES F	lg l	Lk]	Inf	Al
[0]		NULL	0000000000000000	000000	000000	00		0	0	0
[1]	.interp	PROGBITS	0000000000400238	000238	00001c	00	A	0	0	1
[2]	.note.ABI-tag	NOTE	0000000000400254	000254	000020	00	Α	0	0	4
[3]	.note.gnu.build-id	d NOTE	0000000000400274	1 000274	1 000024	1 00	A	0	C) 4
[4]	.gnu.hash	GNU_HASH	0000000000400298	000298	00001c	00	Α	5	0	8
[5]	.dynsym	DYNSYM	00000000004002b8	0002b8	000060	18	A	6	1	8
[6]	.dynstr	STRTAB	0000000000400318	000318	00003f	00	A	0	0	1
[7]	.gnu.version	VERSYM	0000000000400358	000358	800000	02	Α	5	0	2
[8]	.gnu.version_r	VERNEED	0000000000400360	000360	000020	00	A	6	1	8
[9]	.rela.dyn	RELA	0000000000400380	000380	000018	18	A	5	0	8
[10]	.rela.plt	RELA	0000000000400398	000398	000048	18	A	5	12	8
[11]	.init	PROGBITS	00000000004003e0	0003e0	00001a	00	AX	0	0	4
[12]	.plt	PROGBITS	0000000000400400	000400	000040	10	AX	0	0	16
[13]	.text	PROGBITS	0000000000400440	000440	0001b2	00	AX	0	0	16
[14]	.fini	PROGBITS	00000000004005f4	0005f4	000009	00	AX	0	0	4
[15]	.rodata	PROGBITS	0000000000400600	000600	00000d	00	A	0	0	4
[16]	.eh_frame_hdr	PROGBITS	0000000000400610	000610	00003c	00	A	0	0	4
	и так далее									

Объединения секций

- Хранение констант в секции .rodata создаёт некоторое дублирование после линковки. Ниже показаны две одинаковые константы в одном итоговом файле
- Хорошо бы объединять одинаковые секции

```
// foo.c
int foo() {
  float x = 1.0f
.... etc ....
// bar.c
int bar() {
  float x = 1.0f
.... etc ....
```

```
// foo.s
.section .rodata
.LCO:
.long 1065353216
// bar.s
.section .rodata
.LCO:
.long 1065353216
```

```
<foo>:
....
mov LBO, %eax
....
<bar>:
....
mov LB1, %eax
....
```

Объединения секций

- gcc на O2 может помещать константы в специальные секции rodata.cst.<size> где они потом обрабатываются и объединяются линкером
- Это отключается через -fno-merge-constants

```
// foo.c
int foo() {
  float x = 1.0f
.... etc ....
// bar.c
int bar() {
  float x = 1.0f
.... etc ....
```

```
// foo.s
.section .rodata.cst.4
.LCO:
.long 1065353216
// bar.s
.section .rodata.cst.4
.LCO:
.long 1065353216
```

```
<foo>:
....
mov LB0,%eax
....
<bar>:
....
mov LB0,%eax
....
```

Исследование program header

\$ readelf -l a.out --wide

```
Program Headers:
                                PhysAddr FileSiz MemSiz
 Type
            Offset
                   VirtAddr
                                                            Flg Align
 PHDR.
            0x000238 0x000000000400238 0x0000000000400238 0x000001c 0x00001c R
 INTERP
                                                               0x1
    [Requesting program interpreter: /lib64/ld-linux-x86-64.so.2]
 T.NAD
            T.NAD
            0x000e10 0x000000000600e10 0x000000000600e10 0x000230 0x000238 RW
                                                               0x200000
 DYNAMTC
            0x000e28 0x0000000000600e28 0x0000000000600e28 0x0001d0 0x0001d0 RW
                                                               0x8
 NOTE.
            0x000254 0x000000000400254 0x0000000000400254 0x0000044 0x000044 A
                                                               0x4
            0x000610 0x000000000400610 0x000000000400610 0x00003c 0x00
 GNU EH FRAME
                                                               0x4
            GNU STACK
            0x000e10 0x0000000000600e10 0x0000000000600e10 0x0001f0 0x00
 GNU RELRO
```

Интересно, а как они соотносятся с секциями? Их так много...

Исследование program header

\$ readelf -l a.out --wide

```
Section to Segment mapping:
 Segment Sections...
  00
  01 .interp
  02
          .interp .note.ABI-tag .note.gnu.build-id .gnu.hash
.dynsym .dynstr .gnu.version .gnu.version_r .rela.dyn .rela.plt
.init .plt .text .fini .rodata .eh frame hdr .eh frame
  03
          .init array .fini array .jcr .dynamic .got .got.plt .data
.bss
  04
         .dynamic
  05
          .note.ABI-tag .note.gnu.build-id
  06
         .eh_frame_hdr
  07
  08
          .init_array .fini_array .jcr .dynamic .got
```

Gold linker

- Проблемы стандартного GNU LD
 - однопоточность
 - медленная работа с большими объёмами кода
- Решение (только для ELF): gold
- В своё время был разработан как внутренний проект Google, сейчас официально часть GNU Binutils



\$ gcc main.c fact.c -fuse-ld=gold

Проблема межмодульной оптимизации

```
anynum.c

int
any_number() {
  return 5;
}

main.c

int
main() {
  return any_number();
}
```

```
$ gcc main.c anynum.c -02
```

• Будет ли эта программа соптимизирована путём инлайн-подстановки?

Проблема межмодульной оптимизации

```
anynum.c

int
any_number() {
  return 5;
}

main.c

int
main() {
  return any_number();
}
```

```
$ gcc main.c anynum.c -02
```

- Нет, не будет
- Основная проблема: separate translation

Решение: LTO

```
$ gcc main.c anynum.c -02 -flto
```

- LTO (or link-time optimizations)
- Аннотирует объектные файлы исходным кодом
- Использует плагин линкера для оптимизаций аннотированных объектных файлов во время линковки

Скрипты линкера

\$ gcc -Wl,--verbose

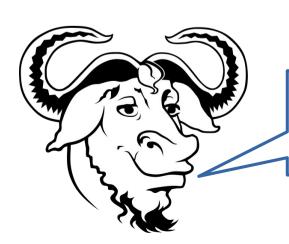
```
using internal linker script:
/* Script for -z combreloc: combine and sort reloc sections */
OUTPUT FORMAT("elf64-x86-64", "elf64-x86-64", "elf64-x86-64")
OUTPUT ARCH(i386:x86-64)
ENTRY( start)
SEARCH DIR("=/usr/local/lib64");
SECTIONS
 PROVIDE ( executable start = SEGMENT START("text-segment",
0x400000);
  . = SEGMENT_START("text-segment", 0x400000) + SIZEOF_HEADERS;
          : { *(.interp) }
  .interp
  .note.gnu.build-id : { *(.note.gnu.build-id) }
.... и так далее ....
```

Скрипты линкера своими руками

```
Директива
SECTIONS { 10 -
                                         SECTIONS
         . = 0x00000000; 2
         .text : { 3
                                            Счетчик
                  abc.o (.text);
                                           локаций
                 def.o (.text)
                                       Начало и конец
                                           секций
SECTIONS {
          = 0x00000000; 
                                           Матчим все
         .text : { * (.text); }
                                        объектные файлы
```

Полезные директивы

- ENTRY определяет входную точку программы (по умолчанию __start)
- OUTPUT_FORMAT формат выходного файла (по умолчанию ELF)
- STARTUP файл (crt0, crti) который должен быть прилинкован в начале исполняемого



Больше полезных директив на sourceware.org/binutils/docs/ld/Scripts.html

Искусство objcopy

```
extern unsigned char _binary_blob_bin_start;
extern unsigned char _binary_blob_bin_end;
extern unsigned char _binary_blob_bin_size;
/* .... */
unsigned char *pblob = &_binary_blob_bin_start;
```

Искусство addr2line

```
1. int main()
2. {
3. int *p = (int*)0xDEADBEEF;
4. *p = 5; /* boom */
5. }
```

```
Segmentation fault
$ dmesg | tail -1
[ 4051.415509] a.out[3346]: segfault at deadbeef
ip 0x04004da sp 0x07fffdd0a97c0 error 6 in a.out[400000+1000]
```

```
$ gcc -g segf.c
$ addr2line -e a.out 0x04004da
segf.c:4
```

Стандартные библиотеки

- Glibc (GNU C Library)
- Microsoft C Run-time Library
- Dietlibc
- uClibc
- Newlib
- Klibc

Легковесные реализации для embedded систем

• Bionic – реализация стандартной библиотеки в Android

Toolchain

• Системы компиляции



Отладчики (Debuggers)

- Отладчики микроархитектуры, такие как OpenOCD (on-chip debugger)
- Отладчики уровня ядра, такие как KGDB или WinDbg
- Отладчики пользовательского уровня, такие как GDB, LLDB, IDB, и прочие



Работа с GDB

```
/* Simple but buggy bubble sort */
void
sort(item *a, int n) {
  int s, i = 0, j = 0;
  for (; i < n && s != 0; i++) {
      s = 0;
      for (j = 0; j < n; j++)
        if (a[j].key > a[j+1].key) {
            item t = a[j];
            a[j] = a[j+1];
            a[j+1] = t;
            s++;
      n--;
```

Настало время отладки...



Работа с GDB

```
$ gdb buggy
(gdb) break sort
Breakpoint 1 at 0x40056f: file buggy-sort.c, line 23.
(gdb) run
Breakpoint 1, sort (a=0x601040, n=5) at buggy-sort.c:23
23 int i = 0, j = 0;
(gdb) next
26 for (; i < n && s != 0; i++)
(gdb) print s
$1 = 0
```

\$ gcc buggy-sort.c -00 -g -o buggy

Отладчик LLDB

• Основная проблема GDB: там отдельный парсер для C++

```
$ gdb a.out
gdb> start
gdb> p [y = std::move(x)] { cout << y << endl; }();</pre>
```

- Поэтому новые возможности языка доходят до GDB с опозданием. Скажем rvalue refs стали возможны через три года после введения в язык
- У отладчика LLDB единый парсер с Clang (прямое переиспользование кода), поэтому его возможности не запаздывают

Отладочная информация

- DWARF -- де-факто стандарт отладочной информации в Unix-подобных системах
- PE/COFF -- де-факто стандарт отладочной информации в Windows-подобных системах
- OMF -- ранее популярный, но устаревший формат

Больше информации по DWARF можно найти на dwarfstd.org

Отладочная информация

```
$ gcc -c -save-temps -00 -g3 -gdwarf-2 fact.c
```

```
fact:
  .file 1 "fact.c"
  .loc 1 3 0
  .cfi startproc
 pushq %rbp
  .cfi def cfa offset 16
  .cfi_offset 6, -16
 movq %rsp, %rbp
  .cfi def cfa register 6
  subq $16, %rsp
 movl %edi, -4(%rbp)
  .loc 1 4 0
  cmpl $1, -4(\%rbp)
 ja .L2
  .loc 1 5 0
 movl $1, %eax
  jmp .L3
```

```
1. unsigned
2. fact (unsigned x)
4. if (x < 2)
5. return 1;
6.
7. return x * fact (x-1);
8. }
```

Отладочная информация

\$ objdump -gdS fact.o > fact.dis

```
fact:
  .file 1 "fact.c"
  .loc 1 3 0
  .cfi startproc
 pushq %rbp
  .cfi_def_cfa_offset 16
  .cfi offset 6, -16
 movq %rsp, %rbp
  .cfi def cfa register 6
  subq $16, %rsp
 movl %edi, -4(%rbp)
  .loc 1 4 0
  cmpl $1, -4(\%rbp)
  ja .L2
  .loc 1 5 0
 movl $1, %eax
  jmp .L3
```

```
00000000000000000000 <fact>:
unsigned fact (unsigned x) {
   0:
         55
                                         %rbp
                                  push
         48 89 e5
                                         %rsp,%rbp
                                   mov
         48 83 ec 10
                                         $0x10,%rsp
                                   sub
  8: 89 7d fc
                                         \%edi,-0x4(\%rbp)
                                  mov
 if (x < 2)
  b: 83 7d fc 01
                                   cmpl
                                         $0x1,-0x4(%rbp)
         77 07
                                   ia
                                         18 <fact+0x18>
   return 1;
        b8 01 00 00 00
                                         $0x1, %eax
                                  mov
         eb 11
                                         29 <fact+0x29>
  16:
                                   jmp
 return x * fact (x-1):
         8b 45 fc
                                         -0x4(\%rbp), %eax
  18:
                                   mov
         83 e8 01
                                         $0x1, %eax
  1b:
                                   sub
                                         %eax,%edi
  1e: 89 c7
                                   mov
  20:
         e8 00 00 00 00
                                  callq 25 < fact + 0x25 >
         Of af 45 fc
                                         -0x4(\%rbp), \%eax
  25:
                                  imul
  29:
                                  leaveq
          с9
  2a:
          c3
                                  retq
```

Соглашения о вызове

X86 prologue

```
fact:
  .file 1 "fact.c"
  .loc 1 3 0
  .cfi startproc
 pushq %rbp
  .cfi_def_cfa_offset 16
  .cfi_offset 6, -16
 movq %rsp, %rbp
  .cfi_def_cfa_register 6
 subq $16, %rsp
 movl %edi, -4(%rbp)
  .loc 1 4 0
```

ARMv8 prologue

```
fact:
  .file 1 "fact.c"
  .loc 1 3 0
  .cfi_startproc
  stmfd sp!, {fp, lr}
  .cfi_def_cfa_offset 8
  .cfi offset 11, -8
  .cfi offset 14, -4
  add fp, sp, #4
  .cfi_def_cfa 11, 4
  sub sp, sp, #8
  str r0, [fp, #-8]
  .loc 1 4 0
```

Соглашения о вызове

- cdecl аргументы через стек, справа налево, обратный сдвиг – caller
- pascal аргументы через стек, слева направо, обратный сдвиг – callee
- fastcall аргументы на регистрах, обратный сдвиг callee
- **stdcall** аргументы через стек, справа налево, обратный сдвиг callee
- tailcall вызов непосредственно перед возвратом, можно не двигать стек

Статический анализ кода

- Массу ошибок можно поймать до того, как программа будет скомпилирована
- Большой выбор инструментов
- Есть как платные (coverity, pvs-studio) так и бесплатные (cpplint, clang-tidy) утилиты
- Проверка может работать на распространенных паттернах ошибок или делать попытки моделирования и model checking

clang-tidy: статический анализ

```
struct B {
  int a;
  virtual int f();
};
struct D : public B {
  int b;
  int f() override;
};
```

```
int use(B b) { return b.f(); }
```

Очевидна ли сейчас проблема?

clang-tidy: статический анализ

```
struct B { int a; virtual int f(); };
struct D : B { int b; int f() override; };
```

```
// intended: use(B &b)?
int use(B b) { return b.f(); }
```

```
int foo () {
  D d;
  return use(d); // slice!
};
```

clang-tidy: обнаружение срезки

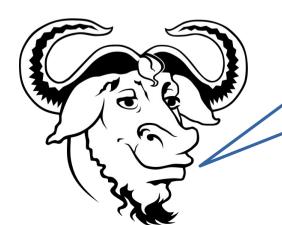
```
$ clang-tidy-3.8 ./slice.cpp -checks=* -- ./slice.cpp
slice.cpp:1:8: warning: Assigned value is garbage or
undefined [clang-analyzer-core.uninitialized.Assign]
struct B { int a; virtual int f(); };
slice.cpp:4:30: Calling implicit copy constructor for 'B'
int foo () { D d; return use(d); };
slice.cpp:1:8: Assigned value is garbage or undefined
struct B { int a; virtual int f(); };
```

Проверки времени исполнения

```
int foo(int* a, int len) {
   assert ((a != NULL) && (len > 1));
   return a[len/2];   /* ORLY? */
}
```

- Статически такое поймать невозможно
- Выход: санитайзеры

```
$ gcc maybe-ub.c -02 -fsanitize=address
```



Больше санитайзеров описано на gcc.gnu.org

Valgrind: основы

- Основная проблема санитайзеров: они портят итоговый код
- Valgrind инструмент, делающий то же самое для оригинальной программы

```
$ gcc maybe-ub.c -02
$ valgrind a.out
==4468== Syscall param
exit_group(status) contains
uninitialised byte(s)
```



При этом valgrind может гораздо больше

Valgrind и утечки памяти

```
int main() {
    char *ix = malloc(10);
    return 0;
}

Эту память никто не освободит
}
```

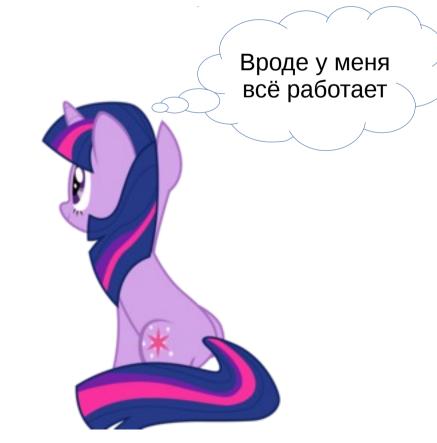
```
$ valgrind -tool=memcheck leak.x
```

```
==4578== HEAP SUMMARY:
==4578== in use at exit: 10 bytes in 1 blocks
==4578== total heap usage: 1 allocs, 0 frees, 10 bytes
allocated
==4578==
==4578== LEAK SUMMARY:
==4578== definitely lost: 10 bytes in 1 blocks
```

Valgrind: ловим data races

```
#include <thread>
#include <iostream>
int x = 0;
void foo () {
  std::thread([&] { ++x; }).detach();
  ++x;
int main () {
  foo ();
  std::cout << x << std::endl;</pre>
  return 0;
```

```
$ g++ race.cpp -pthread
$ ./a.out
1
```



Valgrind: ловим data races

```
#include <thread>
#include <iostream>
int x = 0:
       $ valgrind --tool=helgrind ./a.out
void foo ==4257== Possible data race during write
 std::t
                 of size 4 at 0x602548 by thread #1
 ++x;
      ==4257== at 0x400DEF: foo()
       ==4257== by 0x400E20: main
int mair ==4257== This conflicts with a previous write
                of size 4 by thread #2
 std::d
 return
```

Toolchain

• Системы компиляции



Анализ производительности

- Сколько раз была вызвана та или иная функция?
- Сколько раз исполнялась конкретная строчка кода?
- Сколько времени компилятор провёл в той или иной функции?
- Как аннотировать дугу call-graph стоимостью в процентах времени исполнения

Анализ производительности

- Сколько раз была вызвана та или иная функция?
- Сколько раз исполнялась конкретная строчка кода?
- Сколько времени компилятор провёл в той или иной функции?
- Как аннотировать дугу call-graph стоимостью в процентах времени исполнения

Code coverage

Анализ покрытия: GCOV

```
$ gcc --coverage fact.c main.c -00 -g -lgcov -o test.x
$ ./test.x
```



fact.gcda (gcno)



\$ gcov fact.c



fact.c.gcov

```
1:unsigned
     2:fact (unsigned x)
     3:{
5: 4: if (x < 2)
  5: return 1;
     6:
4: 7: return x * fact (x-1);
     8:}
```

GCOV: аннотация кода

```
static ulong counts[numbbs];
static struct bbobj = { numbbs, &counts, "file1.c"};
static void _GLOBAL_.I.fooBarGCOV() { __bb_init_func(&bbobj); }
```



```
void fooBar (void)
  counts[i]++;
  <bb-i>
  if (condition) {
    counts[j]++;
    <bb-j>
  } else {
    <bb/>bb-k>
```

Анализ производительности

- Сколько раз была вызвана та или иная функция?
- Сколько раз исполнялась конкретная строчка кода?
- Сколько времени компилятор провёл в той или иной функции?
- Как аннотировать дугу call-graph стоимостью в процентах времени исполнения

Анализ производительности

- Сколько раз была вызвана та или иная функция?
- Сколько раз исполнялась конкретная строчка кода?
- Сколько времени компилятор провёл в той или иной функции?
- Как аннотировать дугу call-graph стоимостью в процентах времени исполнения
- Какие программы достаточно репрезентативны для сравнения разных архитектур?

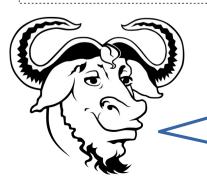
Бенчмарки

- Dhrystone производительность целочисленной арифметики
- Whetstone производительность арифметики с плавающей точкой
- Coremark пакет тестов производительности, покрывающих недостатки Dhrystone
- NAS parallel benchmarks производительность параллельных вычислений

Исследование dhrystone с помощью gprof

```
$ gcc -fno-inline -pg -O2 -DHZ=60 dhry_1.c dhry_2.c -o dhry
$ dhry
$ gprof dhry gmon.out --width=120
```

time	seconds	seconds	calls	ns/call	ns/call	name
24.30	0.33	0.33	10000000	32.56	32.56	Proc_8
23.18	0.64	0.31				main
13.46	0.82	0.18	30000000	6.01	6.01	Proc_7
11.22	0.97	0.15	10000000	15.03	34.07	Proc_1
9.35	1.09	0.13	30000000	4.17	4.17	Func_1
8.60	1.21	0.12	10000000	11.52	15.70	Func_2
3.74	1.26	0.05	10000000	5.01	5.01	Proc_2
3.36	1.30	0.05	10000000	4.51	7.01	Proc_6



Исходники dhrystone 2.1

http://fossies.org/linux/privat/old/dhrystone-2.1.tar.gz Но это не ANSI C, их придется несколько причесать

Профиль по call graph edges

```
index % time
         self children called
                                name
            0.15 0.19 10000000/10000000 main [1]
[2] 25.4 0.15 0.19 10000000 Proc 1 [2]
            0.33 0.00 10000000/10000000 main [1]
[3] 24.3 0.33 0.00 10000000 Proc 8 [3]
            0.06 0.00 10000000/30000000 main [1]
            0.06 0.00 10000000/30000000 Proc_1 [2]
            0.06 0.00 10000000/30000000 Proc 3 [8]
[4] 13.4 0.18 0.00 30000000 Proc 7 [4]
```

```
main → Proc_1 = 25.4%
main → Proc_8 = 24.3%
Proc_3 → Proc_7 = 13.4%
```

Внутри gprof

• mcount: аннотация кода количеством вызовов

• profil: сто раз в секунду информация о

текущей функции

```
fact:
pushq %rbp
movq %rsp, %rbp
call mcount
movl $1, %eax
cmpl $1, %edi
ja .L3
```

Кажется, это может привести к проблемам



Проблемы gprof

```
void work(int n) {
  volatile int i=0; //don't optimize away
  while(i++ < n);
}
void easy() { work(1000); }
void hard() { work(1000*1000); }
int main() { easy(); hard(); }</pre>
```

Какой аннотации дуг мы ожидаем?

Проблемы gprof

```
void work(int n) {
  volatile int i=0; //don't optimize away
  while(i++ < n);
}
void easy() { work(1000); }
void hard() { work(1000*1000); }
int main() { easy(); hard(); }</pre>
```

Примерно такой:

```
main → hard = 99.9%
main → easy = 0.01%
Ho на самом деле...
```

Проблемы gprof

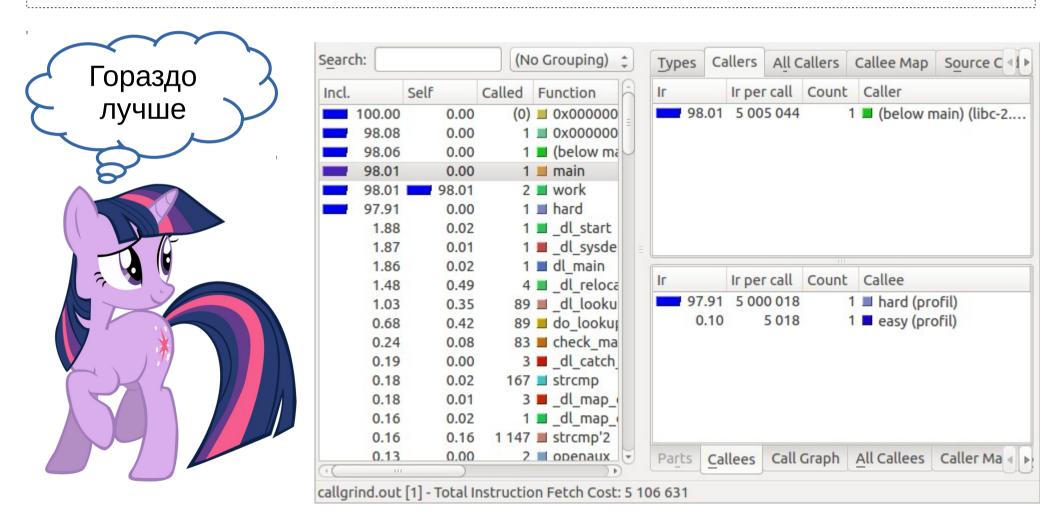
```
void work(int n) {
  volatile int i=0; //don't optimize away
  while(i++ < n);
}
void easy() { work(1000); }
void hard() { work(1000*1000); }</pre>
```

index %	time	self	children	called	name	
		0.00	1.09	1/1	main	[2]
[3]	50.0	0.00	1.09	1	easy [3]	
		0.00	1.09	1/1	main	[2]
[4]	50.0	0.00	1.09	1	hard [4]	

Альтернатива: callgrind

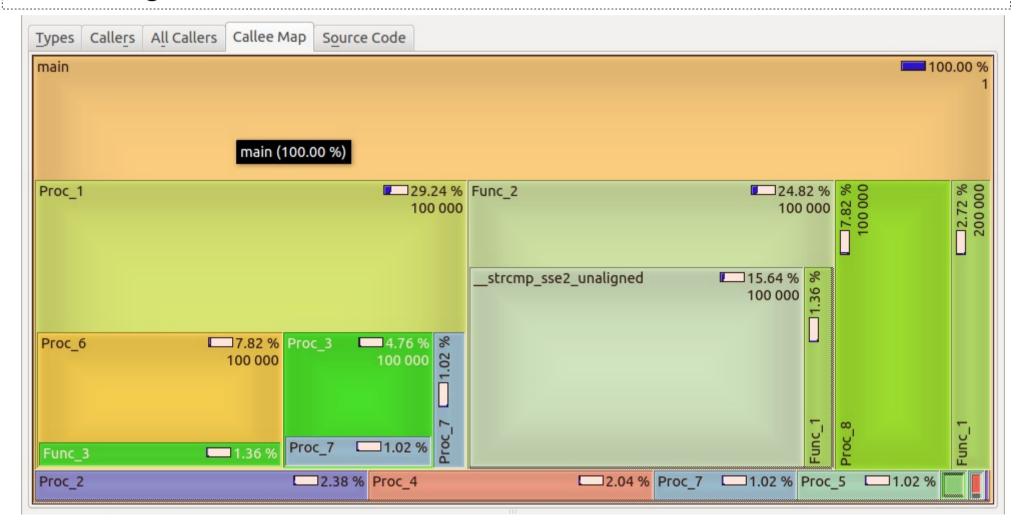
```
$ gcc -02 profil.c -o profil
```

- \$ valgrind --tool=callgrind ./profil
- \$ kcachegrind



Исследование dhrystone с помощью callgrind

```
$ gcc -fno-inline -02 -DHZ=60 dhry_1.c dhry_2.c -o dhry
$ valgrind --tool=callgrind ./dhry
$ kcachegrind
```



Toolchain

• Системы компиляции



Портирование toolchain

• Бэкенд компилятора (GCC, LLVM)

• Бинарные утилиты (as, ld, ...)

• Стандартные библиотеки

• Отладчики (GDB, ...)

Новым архитектурам требуются средства разработки



Перед портированием

Определить набор инструкций (ISA)

Выбрать кодировку для инструкций

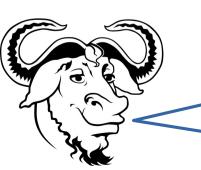
Договориться о синтаксисе ассемблера

Документировать вызов функций (АВІ)

Выбрать формат выходных файлов

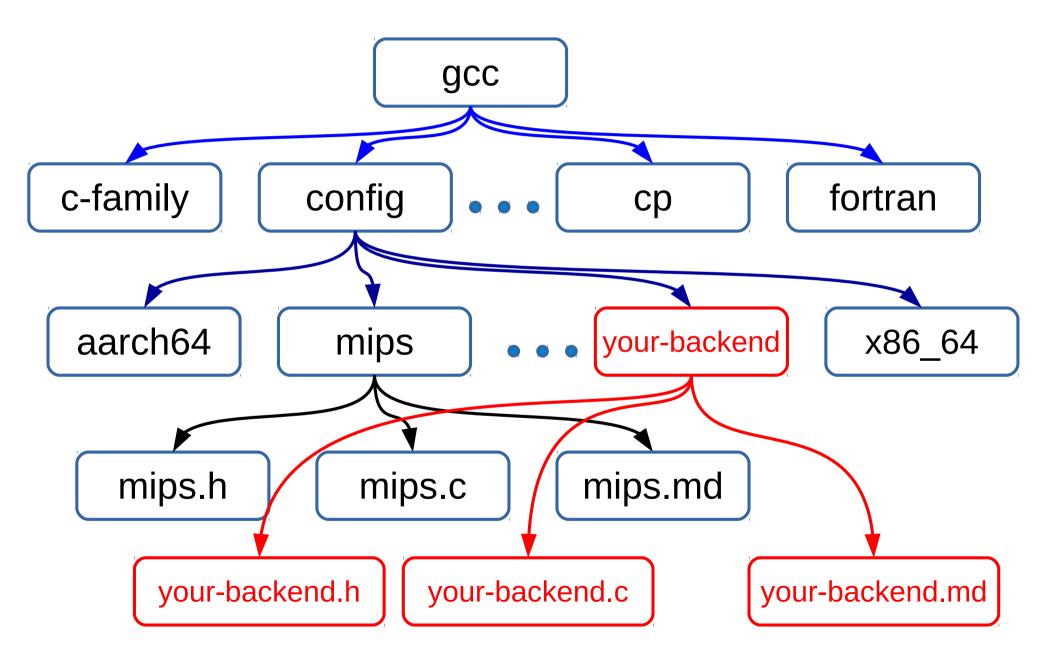
Application binary interface

- Как организована память при исполнении программы
- Как происходит вызов функций и передача параметров
- На какие системные интерфейсы могут полагаться программы



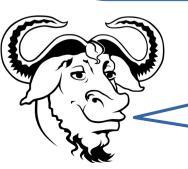
ABI для архитектуры i386: www.sco.com/developers/devspecs/abi386-4.pdf

Внутри GCC: структура файлов



```
(define_insn "*addsi3_extended"
```

```
[(set_attr "alu_type" "add") (set_attr "mode" "SI")])
```



Больше информации про GCC internals gcc.gnu.org/onlinedocs/gccint/

```
[(set_attr "alu_type" "add") (set_attr "mode" "SI")])
```

```
r0:DI = sext:DI (r1:SI + a2:SI)
```

```
[(set_attr "alu_type" "add") (set_attr "mode" "SI")])
```

```
r0:DI = sext:DI (r1:SI + a2:SI) iff condition
```

```
(define insn "*addsi3 extended"
[(set (match_operand:DI 0 "register_operand" "=d,d")
    (sign extend:DI
       (plus:SI (match operand:SI 1 "register operand" "d,d")
            (match operand:SI 2 "arith operand" "d,Q"))))]
"TARGET 64BIT && !TARGET MIPS16"
"@
 addu\t%0,%1,%2
 addiu\t%0,%1,%2"
[(set attr "alu type" "add")
 (set attr "mode" "SI")])
```

```
*addsi3_extended (r0, r1, a2)
```



"addu %0,%1,%2"

Внутри GCC: преобразования инструкций

```
r0:DI = r1:DI and (-1)
```



```
r0:DI = r1:DI << 32
```

Список литературы

Alfred V. Aho, Monica S. Lam, Ravi Sethi, Jeffrey D. Ullman "Compilers: Principles, Techniques, and Tools, 2nd Edition"

Steven Muchnick

"Advanced Compiler Design and Implementation"

John R. Levine

"Linkers and Loaders"

GCC Internals

Binutils Internals



Экзаменационные вопросы

- Препроцессор и фронтенд компилятора
- Бэкенд компилятора
- Ассемблер
- Линкер: статические библиотеки
- Линкер: динамические библиотеки
- Отладка и статический анализ кода
- Анализ производительности
- Портирование компилятора